机器学习中的矩阵向量求导

2024年12月17日 11:10

Ref: https://www.cnblogs.com/pinard/tag/%E7%9F%A9%E9%98%B5%E6%B1%82%E5%AF%BC%20%20%E5%90%91%E9%87%8F%E6%B1%82%E5%AF%BC/

一、求导定义与求导布局

1、矩阵向量求导定义

自变量\因变量	标量y	向量$\mathbf{y}$	矩阵$\mathbf{Y}$
标量x	$\frac{\partial y}{\partial x}$	$\frac{\partial \mathbf{y}}{\partial x}$	$\frac{\partial \mathbf{Y}}{\partial x}$
向量$\mathbf{x}$	$\frac{\partial y}{\partial \mathbf{x}}$	$\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$	$\frac{\partial \mathbf{Y}}{\partial \mathbf{x}}$
矩阵$\mathbf{X}$	$\frac{\partial y}{\partial \mathbf{X}}$	$\frac{\partial \mathbf{y}}{\partial \mathbf{X}}$	$\frac{\partial \mathbf{Y}}{\partial \mathbf{X}}$

2、矩阵向量求导布局

Ref: https://vincentqin.tech/posts/matrix-derivative/

eg. $\begin{bmatrix} x_1 \\ 5x_1 \\ 3x_1 \end{bmatrix}$ 对 x_1 求导，其结果应该是 $\begin{bmatrix} 1 \\ 5 \\ 3 \end{bmatrix}$ 还是 $[1\ 5\ 3]$ 呢？

虽然这一点有时候要视定义而定，分别行向量、列向量和用不就乱套了么

在机器学习中有两个基本的求导布局：分子布局和分母布局

从结果来看，分子布局和分母布局的结果只差一个转置

eg. $f = AX = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} f_1 \\ f_2 \end{bmatrix} = \begin{bmatrix} x_1+2x_2 \\ 3x_1+4x_2 \end{bmatrix}$

$\frac{\partial f}{\partial x} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} \end{bmatrix}$，分子布局　　$\frac{\partial f}{\partial x} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_2}{\partial x_1} \\ \frac{\partial f_1}{\partial x_2} & \frac{\partial f_2}{\partial x_2} \end{bmatrix}$，分母布局

向量一般可以被认为成一维矩阵，默认按列进行排列。 向量对向量求导，如$\partial \mathbf{y}/\partial \mathbf{x}$，其中$\mathbf{y} = [y_1 \ \cdots \ y_m]^\top$以及$\mathbf{x} = [x_1 \ \cdots \ x_n]^\top$

向量默认是列向量！

于是$\partial \mathbf{y}/\partial \mathbf{x}$是一个拥有$m \times n$元素的矩阵，那么应该如何组织这个矩阵呢？目前有两种矩阵排列方式，它们分别是：分子布局（Numerator Layout），分母布局（Denominator Layout）

1）分子布局

一句话就是按照分子的排列方式进行排列，分子原来怎样排列，求导之后的结果就怎样排列，如：

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_m}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_n} \end{bmatrix} = \frac{\partial \mathbf{y}}{\partial \mathbf{x}^\top} \tag{5}$$

上式结果中，分子$\mathbf{y}$的每个元素是是按照下标$1 \ldots m$**按列排布**，于是$\frac{\partial \mathbf{y}}{\partial x} \in \mathbb{R}^{m \times n}$，这种形式也被叫做**雅可比矩阵**[3]（Jacobian matrix），

当y是标量，$\mathbf{x}$是向量时：

$$\frac{\partial y}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y}{\partial x_1} & \cdots & \frac{\partial y}{\partial x_n} \end{bmatrix} \equiv \frac{\partial y}{\partial \mathbf{x}^\top} \tag{6}$$

上述分子布局在标量对向量的求导的数据排布中并不常见。

2）分母布局

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_1}{\partial x_n} & \cdots & \frac{\partial y_m}{\partial x_n} \end{bmatrix} \tag{7}$$

上式结果中，分母$\mathbf{x}$的每个元素是是按照下标$1 \ldots n$按列排布，于是$\frac{\partial \mathbf{y}}{\partial x} \in \mathbb{R}^{n \times m}$

2)分母布局

$$\frac{\partial \mathbf{y}}{\partial x}=\begin{bmatrix}\frac{\partial y_1}{\partial x} & \cdots & \frac{\partial y_m}{\partial x} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_1}{\partial x_n} & \cdots & \frac{\partial y_m}{\partial x_n}\end{bmatrix} \tag{7}$$

上式结果中，分母$\mathbf{x}$的每个元素是是按照下标$1...n$按列排布，于是$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} \in \mathbb{R}^{n \times m}$

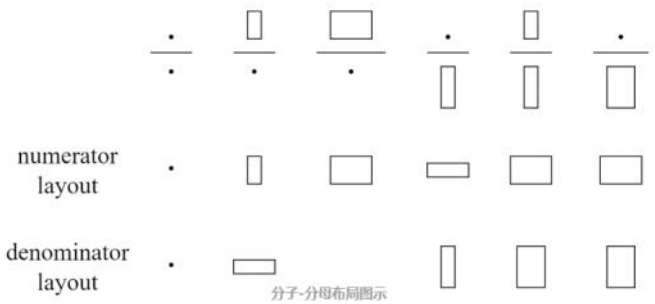
当y是标量，$\mathbf{x}$是向量时：

$$\frac{\partial y}{\partial \mathbf{x}}=\begin{bmatrix}\frac{\partial y}{\partial x_1} \\ \vdots \\ \frac{\partial y}{\partial x_n}\end{bmatrix} \tag{8}$$

这种**标量对向量求导的情况非常常见，通常是以分母布局对求导结果进行排布。**

3) 混合布局

那么向量求导两种方式结果数据排布方式的图示效果如下图所示[1]：



分子-分母布局图示

以上两种形式比较容易搞混（通常在是否使用转置之间徘徊），在使用时务必要说明使用哪种布局！但是实际读论文时很少看到作者写明到底用的哪种，此时需要结合上下文进行判断，推理出论文公式使用的何种布局。另外，值得说明的是，如果作者没有明确说明，自己又懒得看，这时候你可以认为作者使用了“混合布局”，具体地：$\frac{\partial y}{\partial x}$ 按照分子布局，$\frac{\partial y}{\partial x}$ 按照分母布局[3]。

混合布局（默认布局）
① 向量或矩阵对标量求导 ⇒ 分子布局
② 标量对向量或矩阵求导 ⇒ 分母布局
③ 向量对向量的求导 ⇒ 分子布局

具体总结如下：

自变量\因变量	标量y 1×1	列向量$\mathbf{y}$ m×1	矩阵$\mathbf{Y}$ p×q
标量x 1×1	/	$\frac{\partial \mathbf{y}}{\partial x}$ 分子布局：m维列向量（默认布局） 分母布局：m维行向量	$\frac{\partial \mathbf{Y}}{\partial x}$ 分子布局：$p \times q$矩阵（默认布局） 分母布局：$q \times p$矩阵
列向量$\mathbf{x}$ n×1	$\frac{\partial y}{\partial \mathbf{x}}$ 分子布局：n维行向量 分母布局：n维列向量（默认布局）	$\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$ 分子布局：$m \times n$雅克比矩阵（默认布局） 分母布局：$n \times m$梯度矩阵	/
矩阵$\mathbf{X}$ m×n	$\frac{\partial y}{\partial \mathbf{X}}$ 分子布局：$n \times m$矩阵 分母布局：$m \times n$矩阵（默认布局）	/	/

二、矩阵向量求导之定义法

1. 标量对向量求导的一些基本法则

在我们寻找一些简单的方法前，我们简单看下标量对向量求导的一些基本法则，这些法则和标量对标量求导的过程类似。

1） 常量对向量的求导结果为0。

2）线性法则：如果f, g都是实值函数，c_1, c_2为常数，则：

$$\frac{\partial(c_1 f(\mathbf{x}) + c_2 g(\mathbf{x})}{\partial \mathbf{x}} = c_1 \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} + c_2 \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}}$$

3）乘法法则：如果f, g都是实值函数，则：

$$\frac{\partial f(\mathbf{x}) g(\mathbf{x})}{\partial \mathbf{x}} = f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}} + \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} g(\mathbf{x})$$

要注意的是如果不是实值函数，则不能这么使用乘法法则。

4）除法法则：如果f, g都是实值函数，且$g(\mathbf{x}) \neq 0$，则：

$$\frac{\partial f(\mathbf{x})/g(\mathbf{x})}{\partial \mathbf{x}} = \frac{1}{g^2(\mathbf{x})}(g(\mathbf{x}) \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} - f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}})$$

2、标量对向量求导

1) $\frac{\partial a^T x}{\partial x}$，由 $\frac{\partial \sum_{i=1}^{n} a_i x_i}{\partial x_k} = \frac{\partial a_k x_k}{\partial x_k} = a_k$ 可得，$\frac{\partial a^T x}{\partial x} = a$

2) $\frac{\partial x^T x}{\partial x}$，由 $\frac{\partial \sum_{i=1}^{n} x_i^2}{\partial x_k} = \frac{\partial x_k^2}{\partial x_k} = 2x_k$ 可得，$\frac{\partial x^T x}{\partial x} = 2x$

3) $\frac{\partial x^T A x}{\partial x}$，由 $\frac{\partial \sum_{i=1}^{n}\sum_{j=1}^{n} A_{ij} \cdot x_i \cdot x_j}{\partial x_k} = \underset{(i \neq k, j \neq k)}{0} + \underset{(j=k)}{\frac{\partial \sum_{i=1}^{n} A_{ik} \cdot x_i \cdot x_k}{\partial x_k}} + \underset{(i=k)}{\frac{\partial \sum_{j=1}^{n} A_{kj} \cdot x_k \cdot x_j}{\partial x_k}}$

$= \sum_{i=1}^{n} A_{ik} \cdot x_i + \sum_{j=1}^{n} A_{kj} \cdot x_j$，可得 $\frac{\partial x^T A x}{\partial x} = A^T x + A x$

3. 标量对矩阵求导

1) $\frac{\partial a^T X b}{\partial X}$，由 $\frac{\partial \sum_{p=1}^{m}\sum_{q=1}^{n} a_p \cdot X_{pq} \cdot b_q}{\partial X_{ij}} = \frac{\partial a_i X_{ij} b_j}{\partial X_{ij}} = a_i b_j$ 可得 $\frac{\partial a^T X b}{\partial X} = a b^T$ (分母布局)

4. 用定义法求解向量对向量求导

1) $\frac{\partial A x}{\partial x}$，由 $\frac{\partial A_i X}{\partial X_j} = \frac{\partial \sum_{k=1} A_{ik} X_k}{\partial X_j} = \frac{\partial A_{ij} \cdot X_j}{\partial X_j} = A_{ij}$ 可得 $\frac{\partial A x}{\partial x} = A$

$A \in R^{n \times m}$，$x \in R^{m \times 1}$

A的第 i 行与 X 相乘对 X 的第 j 个向量求导

5. 定义法矩阵向量求导的局限

使用定义法虽然已经求出一些简单的向量矩阵求导的结果，但是对于复杂的求导式子，则中间运算会很复杂，同时求导出的结果排列也是很头痛的。下一篇我们讨论使使用矩阵微分和迹函数的方法来求解矩阵向量求导。

三、矩阵求导之微分法

$\sum_{i=1}^{n} a_i b_i$ —向量化→ $a^T b$

$df(x) = f'(x)\,dx$

$$\mathrm{tr}(\mathbf{AB}) = \sum_{i=1}^{n} (\mathbf{AB})_{ii} = \sum_{i=1}^{n}\sum_{j=1}^{m} \mathbf{A}_{ij}\mathbf{B}_{ji} = \sum_{j=1}^{m}\sum_{i=1}^{n} \mathbf{B}_{ji}\mathbf{A}_{ij} = \sum_{j=1}^{m} (\mathbf{BA})_{jj} = \mathrm{tr}(\mathbf{BA})$$

1. 矩阵微分

1. 矩阵微分

在高数里面我们学习过标量的导数和微分，他们之间有这样的关系：$df = f'(x)dx$。如果是多变量的情况，则微分可以写成：

$$df = \sum_{i=1}^{n} \frac{\partial f}{\partial x_i} dx_i = (\frac{\partial f}{\partial \mathbf{x}})^T d\mathbf{x}$$

从上次我们可以发现标量对向量的求导和它的向量微分有一个转置的关系。

现在我们再推广到矩阵。对于矩阵微分，我们的定义为：

$$df = \sum_{i=1}^{m} \sum_{j=1}^{n} \frac{\partial f}{\partial X_{ij}} dX_{ij} = tr((\frac{\partial f}{\partial \mathbf{X}})^T d\mathbf{X})$$

其中第二步使用了矩阵迹的性质，即迹函数等于主对角线的和。即

$$tr(A^T B) = \sum_{i,j} A_{ij} B_{ij}$$ ⇒ 对应下标相等的情况

从上面矩阵微分的式子，我们可以看到矩阵微分和它的导数也有一个转置的关系，不过在外面套了一个迹函数而已。由于标量的迹函数就是它本身，那么矩阵微分和向量微分可以统一表示，即：

$$df = tr((\frac{\partial f}{\partial \mathbf{X}})^T d\mathbf{X}) \quad df = tr((\frac{\partial f}{\partial \mathbf{x}})^T d\mathbf{x})$$

$tr(a) = a$
a是标量或$R^{1\times 1}$

e.g $f\left(\begin{bmatrix} x_1 & x_2 \end{bmatrix}\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \begin{bmatrix} x_1^2 & 2x_1x_2 \\ 3x_1x_2 & 4x_2^2 \end{bmatrix}$，求 df

$$\begin{bmatrix} \frac{\partial f}{\partial x_{11}} & \frac{\partial f}{\partial x_{12}} & \frac{\partial f}{\partial x_{13}} \\ \frac{\partial f}{\partial x_{21}} & \frac{\partial f}{\partial x_{22}} & \frac{\partial f}{\partial x_{23}} \end{bmatrix} \xrightarrow{\text{transpose}} \begin{pmatrix} \frac{\partial f}{\partial x_{11}} & \frac{\partial f}{\partial x_{21}} \\ \frac{\partial f}{\partial x_{12}} & \frac{\partial f}{\partial x_{22}} \\ \frac{\partial f}{\partial x_{13}} & \frac{\partial f}{\partial x_{23}} \end{pmatrix} \begin{bmatrix} dx_{11} & dx_{12} & dx_{13} \\ dx_{21} & dx_{22} & dx_{23} \end{bmatrix}$$

3×2 $\quad 2\times 3$

$$= \begin{bmatrix} \checkmark & \times & \times \\ \times & \checkmark & \times \\ \times & \times & \checkmark \end{bmatrix}$$

2. 矩阵微分的性质

我们在讨论如何使用矩阵微分来求导前，先看看矩阵微分的性质：

1) 微分加减法：$d(X+Y) = dX + dY, d(X-Y) = dX - dY$
2) 微分乘法：$d(XY) = (dX)Y + X(dY)$ 注意 X, Y 的顺序 → 扩展 $d(X_1X_2\cdots X_n) = d(X_1)X_2\cdots X_n + X_1 d(X_2)X_3\cdots X_n + \cdots + X_1\cdots X_{n-1}d(X_n)$
3) 微分转置：$d(X^T) = (dX)^T$
4) 微分的迹：$dtr(X) = tr(dX)$
5) 微分哈达马乘积：$d(X \odot Y) = X \odot dY + dX \odot Y$ $(X\odot Y)_{ij} = X_{ij}Y_{ij}$
6) 逐元素求导：$d\sigma(X) = \sigma'(X) \odot dX$
7) 逆矩阵微分：$dX^{-1} = -X^{-1}dXX^{-1}$
8) 行列式微分：$d|X| = |X|tr(X^{-1}dX)$

有了这些性质，我们再来看看如何由矩阵微分来求导数。

1) 证明 $d(X\odot Y) = X\odot dY + Y\odot dX$

给定矩阵 $\mathbf{A}$ 和 $\mathbf{B}$：

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix}.$$

它们的哈达马乘积是：

$$\mathbf{C} = \mathbf{A} \circ \mathbf{B} = \begin{bmatrix} a_{11}b_{11} & a_{12}b_{12} \\ a_{21}b_{21} & a_{22}b_{22} \end{bmatrix}.$$

设 $\mathbf{A} \circ \mathbf{B} = \mathbf{C}$，则：

$$C_{ij} = A_{ij} B_{ij}.$$

对 C_{ij} 求微分：

$$dC_{ij} = B_{ij}\, dA_{ij} + A_{ij}\, dB_{ij}.$$

将逐元素的微分结果重新组织成矩阵形式，得：

$$d(\mathbf{A} \circ \mathbf{B}) = (\mathbf{B} \circ d\mathbf{A}) + (\mathbf{A} \circ d\mathbf{B}).$$

2) 证明 $d(X^{-1}) = -X^{-1} \cdot dX \cdot X^{-1}$

$d(XX^{-1}) = X dX^{-1} + dX \cdot X^{-1} = d(I) = 0$

$X \cdot dX^{-1} = -dX \cdot X^{-1}$

$dX^{-1} = -X^{-1} \cdot dX \cdot X^{-1}$

3) 证明 $d|X| = |X| \cdot tr(X^{-1} dX)$ 太难了...

3. 使用微分法求解矩阵向量求导

1) $y = a^T X b$，求 $\frac{\partial y}{\partial X}$

① $dy = d(a^T X b) = d(a^T) X b + a^T d(X) b + a^T X d(b) = a^T d(X) b$

② $dy = tr(dy) = tr(a^T d(X) b) = tr(b a^T dX)$

③ 由 $df = tr\left(\left(\frac{\partial f}{\partial X}\right)^T dX\right)$ 可得

$dy = tr((ab^T)^T dX)$，故 $\frac{\partial y}{\partial X} = ab^T$

总结：利用微分法求导的一般流程

① 先对 y/f 求微分

② 对微分作迹变换，凑出 $tr\left(\left(\frac{\partial f}{\partial X}\right)^T dX\right)$

③ 得到求导结果 $\frac{\partial f}{\partial X}$

这里需要用到的迹函数的技巧主要有这么几个：

1) 标量的迹等于自己：$tr(x) = x$

2) 转置不变：$tr(A^T) = tr(A)$

3) 交换率：$tr(AB) = tr(BA)$，需要满足 A, B^T 同维度。

4) 加减法：$tr(X+Y) = tr(X) + tr(Y), tr(X-Y) = tr(X) - tr(Y)$

5) 矩阵乘法和迹交换：$tr((A \odot B)^T C) = tr(A^T (B \odot C))$，需要满足 A, B, C 同维度。

2) $y = a^T \cdot \exp(Xb)$，求 $\frac{\partial y}{\partial X}$

① $dy = a^T d[\exp(Xb)] + d(a^T) \cdot \exp[Xb]$

② $tr(dy) = tr(a^T d[\exp(Xb)])$ $d\delta(x) = \delta'(x) \odot dx$

$tr((A \odot B)^T \cdot C) = tr(A^T (B \odot C))$

$= tr\left(a^T \cdot (\exp(Xb) \odot d(Xb))\right)$

$= tr\left([a \odot \exp(Xb)]^T \cdot d(Xb)\right)$

$= tr\left(b \cdot [a \odot \exp(Xb)]^T \cdot dX\right)$

③ 得 $\frac{\partial f}{\partial X} = [a \odot \exp(Xb)] b^T$

4. 迹函数对向量矩阵求导

1) $X \in R^{n \times n}$，求 $\frac{\partial tr(X)}{\partial X}$

$\frac{\partial tr(X)}{\partial X} = \frac{\partial \sum_{i=1}^{n} X_{ii}}{X} = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases} = 1_{n \times n}$

2) $X \in R^{n\times m}$, $A \in R^{m\times n}$, 求 $\frac{\partial tr(AX)}{\partial X}$

$$\frac{\partial tr(AX)}{\partial X} = \frac{\partial \sum_{i=1}^{n}\sum_{j=1}^{m} A_{ij}\cdot X_{ji}}{\partial X}$$

由 $\frac{\partial \sum_{i=1}^{n}\sum_{j=1}^{m} A_{ij}\cdot X_{ji}}{\partial X_{pq}} = A_{qp}$ 可得

$$\frac{\partial tr(AX)}{\partial X} = A^T$$

3) $X \in R^{n\times n}$, $A \in R^{n\times n}$, 求 $\frac{\partial tr(XA)}{\partial X}$

① $\frac{\partial tr(XA)}{\partial X} = \frac{\partial \sum_{i=1}^{n}\sum_{j=1}^{n} X_{ij}\cdot A_{ji}}{\partial X}$

由 $\frac{\partial \sum_{i=1}^{n}\sum_{j=1}^{n} X_{ij}\cdot A_{ji}}{\partial X_{pq}} = A_{qp}$ 可得

$$\frac{\partial tr(XA)}{\partial X} = A^T$$

② $\frac{tr(XA)}{\partial X} = \frac{tr(AX)}{\partial X} = A^T$

4) $X \in R^{n\times n}$, $A \in R^{n\times n}$, 求 $\frac{\partial tr(X^TAX)}{\partial X}$

$$d(XAX) = d(X^T)\cdot AX + Xd(A)X + X^TAd(X)$$
$$= d(X^T)AX + X^TAd(X)$$

$$tr(d(XAX)) = tr(d(X^T)\cdot AX + X^TAd(X))$$
$$= tr([d(X)]^TAX + X^TAd(X))$$
$$= tr([d(X)]^TAX) + tr(X^TAd(X))$$
$$= tr(d(X)A^TX^T) + tr(X^TAd(X))$$
$$= tr(X^TA^Td(X)) + tr(X^TAd(X))$$
$$= tr(X^T(A+A^T)dX)$$
$$= ([(A+A^T)X]^TdX)$$

故 $\frac{\partial f}{\partial X} = (A+A^T)X$

5) $\frac{\partial tr(B^TX^TCXB)}{\partial X}$

$$d(B^TX^TCXB) = B^Td(X^T)CXB + B^TX^TCd(X)B$$

$$tr(dB^TX^TCXB) = tr(B^Td(X^T)CXB) + tr(B^TX^TCd(X)B)$$
$$= tr([d(X)B]^TCXB) + tr(B^TX^TCd(X)B)$$
$$= tr(d(X)BC^TX^TB^T) + tr(B^TX^TCd(X)B)$$
$$= tr(B^TX^TC^Td(X)B) + tr(B^TX^TCd(X)B) \quad tr(XY) = tr(YX)$$
$$= tr(BB^TX^TC^Td(X)) + tr(BB^TX^TCd(X))$$
$$= [(\quad)BB^T]^Td(X)]$$

$= tr(\quad)$

$= tr(BB^TX^TC^Td(X)) + tr(BB^TX^TC\,d(X))$

$= tr(BB^TX^T(C+C^T)d(X)) = tr[((C+C^T)XBB^T)^Td(X)]$

故可得 $\frac{df}{dX} = (C+C^T)XBB^T$

5. 微分法求导小结

使用矩阵微分，可以在不对向量或矩阵中的某一元素单独求导再拼接，因此会比较方便，当然熟练使用的前提是对上面矩阵微分的性质，以及迹函数的性质熟练运用。

还有一些场景，求导的自变量和因变量直接有复杂的多层链式求导的关系，此时微分法使用起来也有些麻烦。如果我们可以利用一些常用的简单求导结果，再使用链式求导法则，则会非常的方便。因此下一篇我们讨论向量矩阵求导的链式法则。

四、矩阵向量求导之链式法则

本文的标量对向量的求导，标量对矩阵的求导使用分母布局， 向量对向量的求导使用分子布局。如果遇到其他资料求导结果不同，请先确认布局是否一样。

1. 向量对向量求导的链式法则

首先我们来看看向量对向量求导的链式法则。假设多个向量存在依赖关系，比如三个向量$\mathbf{x} \to \mathbf{y} \to \mathbf{z}$存在依赖关系，则我们有下面的链式求导法则：

$$\frac{\partial \mathbf{z}}{\partial \mathbf{x}} = \frac{\partial \mathbf{z}}{\partial \mathbf{y}} \frac{\partial \mathbf{y}}{\partial \mathbf{x}}$$

该法则也可以推广到更多的向量依赖关系。但是要注意的是要求所有有依赖关系的变量都是向量，如果有一个$\mathbf{Y}$是矩阵，，比如是$\mathbf{x} \to \mathbf{Y} \to \mathbf{z}$， 则上式并不成立。

从矩阵维度相容的角度也很容易理解上面的链式法则，假设$\mathbf{x}, \mathbf{y}, \mathbf{z}$分别是$m, n. p$维向量，则求导结果$\frac{\partial z}{\partial x}$是一个$p \times m$的雅克比矩阵，而右边$\frac{\partial z}{\partial y}$是一个$p \times n$的雅克比矩阵，$\frac{\partial y}{\partial x}$是一个$n \times m$的矩阵，两个雅克比矩阵的乘积维度刚好是$p \times m$，和左边相容。

2. 标量对多个向量的链式求导法则

在我们的机器学习算法中，最终要优化的一般是一个标量损失函数，因此最后求导的目标是标量，无法使用上一节的链式求导法则，比如2向量，最后到1标量的依赖关系：$\mathbf{x} \to \mathbf{y} \to z$，此时很容易发现维度不相容。

假设$\mathbf{x}, \mathbf{y}$分别是m, n维向量，那么$\frac{\partial z}{\partial \mathbf{x}}$的求导结果是一个$m \times 1$的向量，而$\frac{\partial z}{\partial \mathbf{y}}$是一个$n \times 1$的向量，$\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$是一个$n \times m$的雅克比矩阵,右边的向量和矩阵是没法直接乘的。

但是假如我们把标量求导的部分都做一个转置，那么维度就可以相容了，也就是：

$$(\frac{\partial z}{\partial \mathbf{x}})^T = (\frac{\partial z}{\partial \mathbf{y}})^T \frac{\partial \mathbf{y}}{\partial \mathbf{x}}$$

但是毕竟我们要求导的是$(\frac{\partial z}{\partial \mathbf{x}})$,而不是它的转置，因此两边转置我们可以得到标量对多个向量求导的链式法则：

$$\frac{\partial z}{\partial \mathbf{x}} = (\frac{\partial \mathbf{y}}{\partial \mathbf{x}})^T \frac{\partial z}{\partial \mathbf{y}}$$

如果是标量对更多的向量求导,比如$\mathbf{y_1} \to \mathbf{y_2} \to \ldots \to \mathbf{y_n} \to z$，则其链式求导表达式可以表示为：

$$\frac{\partial z}{\partial \mathbf{y_1}} = (\frac{\partial \mathbf{y_n}}{\partial \mathbf{y_{n-1}}} \frac{\partial \mathbf{y_{n-1}}}{\partial \mathbf{y_{n-2}}} \cdots \frac{\partial \mathbf{y_2}}{\partial \mathbf{y_1}})^T \frac{\partial z}{\partial \mathbf{y_n}}$$

这里我们给一个最常见的最小二乘法求导的例子。最小二乘法优化的目标是最小化如下损失函数：

$$l = (X\theta - y)^T(X\theta - y)$$

我们优化的损失函数l是一个标量，而模型参数θ是一个向量，期望l对θ求导，并求出导数等于0时候的极值点。我们假设向量$z = X\theta - y$, 则$l = z^Tz$，$\theta \to z \to l$存在链式求导的关系，因此：

$$\frac{\partial l}{\partial \theta} = (\frac{\partial z}{\partial \theta})^T \frac{\partial l}{\partial \mathbf{z}} = X^T(2z) = 2X^T(X\theta - y)$$

其中最后一步转换使用了如下求导公式：

$$\frac{\partial X\theta - y}{\partial \theta} = X$$

$$\frac{\partial z^Tz}{\partial z} = 2z$$

这两个式子我们在前几篇里已有求解过，现在可以直接拿来使用了，非常方便。

当然上面的问题使用微分法求导数也是非常简单的，这里只是给出链式求导法的思路。

3. 标量对多个矩阵的链式求导法则

下面我们再来看看标量对多个矩阵的链式求导法则，假设有这样的依赖关系：$\mathbf{X} \to \mathbf{Y} \to z$,那么我们有：

$$\frac{\partial z}{\partial x_{ij}} = \sum_{k,l} \frac{\partial z}{\partial Y_{kl}} \frac{\partial Y_{kl}}{\partial X_{ij}} = tr((\frac{\partial z}{\partial Y})^T \frac{\partial Y}{\partial X_{ij}})$$

这里大家会发现我们没有给出基于矩阵整体的链式求导法则，主要原因是矩阵对矩阵的求导是比较复杂的定义，我们目前也未涉及。因此只能给出对矩阵中一个标量的链式求导方法。这个方法并不实用，因为我们并不想每次都基于定义法来求导最后再去排列求导结果。

虽然我们没有全局的标量对矩阵的链式求导法则，但是对于一些线性关系的链式求导，我们还是可以得到一些有用的结论的。

我们来看这个常见问题：A, X, B, Y都是矩阵，z是标量，其中$z = f(Y), Y = AX + B$,我们要求出$\frac{\partial z}{\partial X}$,这个问题在机器学习中是很常见的。此时，我们并不能直接整体使用矩阵的链式求导法则，因为矩阵对矩阵的求导结果不好处理。

这里我们回归初心，使用定义法试一试,先使用上面的标量链式求导公式：

$$\frac{\partial z}{\partial x_{ij}} = \sum_{k,l} \frac{\partial z}{\partial Y_{kl}} \frac{\partial Y_{kl}}{\partial X_{ij}}$$

我们再来看看后半部分的导数：

$$\frac{\partial Y_{kl}}{\partial X_{ij}} = \frac{\partial \sum_s (A_{ks} X_{sl})}{\partial X_{ij}} = \frac{\partial A_{ki} X_{il}}{\partial X_{ij}} = A_{ki} \delta_{lj}$$

其中δ_{lj}在$l = j$时为1，否则为0.

那么最终的标签链式求导公式转化为：

$$\frac{\partial z}{\partial x_{ij}} = \sum_{k,l} \frac{\partial z}{\partial Y_{kl}} A_{ki} \delta_{lj} = \sum_k \frac{\partial z}{\partial Y_{kj}} A_{ki}$$

即矩阵A^T的第i行和$\frac{\partial z}{\partial Y}$的第j列的内积。排列成矩阵即为：

$$\frac{\partial z}{\partial X} = A^T \frac{\partial z}{\partial Y}$$

总结下就是：

$$z = f(Y), Y = AX + B \to \frac{\partial z}{\partial X} = A^T \frac{\partial z}{\partial Y}$$

这结论在$\mathbf{x}$是一个向量的时候也成立，即：

$$z = f(\mathbf{y}), \mathbf{y} = A\mathbf{x} + \mathbf{b} \to \frac{\partial z}{\partial \mathbf{x}} = A^T \frac{\partial z}{\partial \mathbf{y}}$$

如果要求导的自变量在左边，线性变换在右边，也有类似稍有不同的结论如下，证明方法是类似的，这里直接给出结论：

$$z = f(Y), Y = XA + B \to \frac{\partial z}{\partial X} = \frac{\partial z}{\partial Y} A^T$$

$$z = f(\mathbf{y}), \mathbf{y} = X\mathbf{a} + \mathbf{b} \to \frac{\partial z}{\partial \mathbf{X}} = \frac{\partial z}{\partial \mathbf{y}} a^T$$

使用好上述四个结论，对于机器学习尤其是深度学习里的求导问题可以非常快的解决,大家可以试一试。

4. 矩阵向量求导小结

矩阵向量求导在前面我们讨论三种方法，定义法，微分法和链式求导法。在同等情况下，优先考虑链式求导法，尤其是第三节的四个结论。其次选择微分法、在没有好的求导方法的时候使用定义法是最后的保底方案。

基本上大家看了系列里这四篇后对矩阵向量求导就已经很熟悉了，对于机器学习中出现的矩阵向量求导问题已足够。这里还没有讲到的是矩阵对矩阵的求导，还有矩阵对向量，向量对矩阵求导这三种形式，这个我们在系列的下一篇，也是最后一篇简单讨论一下，如果大家只是关注机器学习的优化问题，不涉及其他应用数学问题的，可以不关注。

五、应用

最小化误差 E:

$$E = \sum_{i=1}^{n} (a_i^T x - b_i)^2 = \|Ax - b\|^2$$

$$= (Ax-b)^T (Ax-b)$$

$$= (x^T A^T - b^T)(Ax-b)$$

$$= x^T A^T A x - x^T A^T b - b^T A x + b^T b$$

$$\frac{\partial E}{\partial x} = \frac{\partial x^T A^T A x}{\partial x} - \frac{\partial x^T A^T b}{\partial x} - \frac{\partial b^T A x}{\partial x}$$

其中, $tr(d(X^TA^TAX)) = tr(d(X^T)A^TAX + X^TA^TA\,d(X))$

$= tr(d(X)^TA^TAX + X^TA^TA\,d(X))$

$= tr(X^TA^TA\,d(X) + X^TA^TA\,d(X))$

$= 2tr(X^TA^TA\,d(X))$

$= 2tr((A^TAX)^T d(X))$

故 $\frac{\partial X^TA^TAX}{dX} = 2A^TAX$

$tr(d(X^TA^Tb)) = tr(d(X^T)A^Tb) = tr(b^TA\,d(X)) = tr[(A^Tb)^T d(X)]$

故 $\frac{\partial X^TA^Tb}{\partial X} = A^Tb$

$tr(d(b^TAX) = tr(b^TA\,d(X)) = tr(A^Tb\,d(X))$

故 $\frac{\partial b^TAX}{\partial X} = A^Tb$

综上可得 $\frac{\partial E}{\partial X} = 2A^TAX - 2A^Tb$

令 $\frac{\partial E}{\partial X} = 0$ 可得 $A^TAX = A^Tb$, $X = (A^TA)^{-1}A^Tb$

即 $X = (A^TA)^{-1}A^Tb$ 就是上述最小二乘问题的解